

Aether Lab

API распознавания файлов

Руководство для интеграции • PDF и структурированные данные документов

Описание подготовлено по исходному коду ветки master, коммит 845c74214591. Доступность production и соответствие установленной версии этому коду не проверялись. Примеры ответов иллюстративные; идентификаторы и токены — условные.

1. Назначение и схема работы

API принимает ранее загруженные файлы и запускает асинхронную задачу. Обработка включает OCR (извлечение текста), подбор или создание шаблона и структурирование документа языковой моделью. Результат содержит исходный распознанный текст и JSON по схеме шаблона.

Загрузка файла → ID файла → Создание задачи → Опрос статуса
→ Текст + JSON-результат

Базовый адрес из конфигурации развёртывания: <https://aether-lab.ru>. Все приведённые пути относительно к нему; завершающий слеш следует сохранять. Это API для авторизованного клиента, не анонимный доступ. Отдельный публичный синхронный метод «PDF → текст» в исследованных маршрутах не найден.

2. Авторизация

Контур	Способ доступа
/api/recognition/	JWT: Authorization: Bearer <access_token>, либо сессия Django.
/api/file-manager/	X-Billing-Token: <billing_token>, либо Authorization: Billing <billing_token>, либо сессия Django. JWT здесь не подключён.

Для сквозного сценария используйте billing token для загрузки и JWT для распознавания одного пользователя, либо одну авторизованную сессию. При сессионной авторизации изменяющие запросы требуют CSRF. Billing token — не JWT; не подставляйте JWT в заголовок X-Billing-Token.

```
POST /api/token/  
Content-Type: application/json
```

```
{"username": "<username>", "password": "<password>"}
```

```
// Стандартный ответ SimpleJWT  
{"access": "<access_token>", "refresh": "<refresh_token>"}
```

```
POST /api/token/refresh/  
Content-Type: application/json
```

```
{"refresh": "<refresh_token>"}
```

```
// Ответ: {"access": "<new_access_token>"}
```

По production-настройкам репозитория access token действует 1 час, refresh token — 1 сутки. Храните токены вне кода и логов; передавайте только по HTTPS. У billing token должен быть активный расчётный аккаунт или активное корпоративное членство.

3. Справочник методов

Метод	Путь	Назначение
POST	/api/file-manager/files/	Загрузить файл → 201
GET	/api/file-manager/files/	Список собственных файлов → 200
GET	/api/file-manager/files/{id}/	Карточка собственного файла → 200
GET	/api/file-manager/files/{id}/download/	Скачать исходный файл
POST	/api/recognition/tasks/	Создать задачу → 201
GET	/api/recognition/tasks/	Список собственных задач → 200
GET	/api/recognition/tasks/{id}/	Статус, текст и JSON → 200
POST	/api/recognition/templates/	Создать шаблон по примерам → 201
GET	/api/recognition/templates/	Список шаблонов → 200
GET	/api/recognition/templates/{id}/	JSON Schema и примеры → 200

DELETE на detail-маршрутах файлов, задач и шаблонов возвращает 204. Удаление файла удаляет и физический файл; удаление записи задачи не является подтверждённым способом отменить фоновую обработку. Не используйте PUT/PATCH как контракт обновления: для задач и шаблонов update не реализован, для файлов поля ответа только для чтения.

4. Загрузка файла

POST /api/file-manager/files/. Рекомендуемый тип тела — multipart/form-data. Поле file обязательно; filename — необязательное имя файла, name — отображаемое имя, content — необязательный текст у записи файла (не входной OCR-текст задачи).

```
curl --fail-with-body -sS \
  "https://aether-lab.ru/api/file-manager/files/" \
  -H "X-Billing-Token: $BILLING_TOKEN" \
  -F "file=@./document.pdf;type=application/pdf" \
  -F "filename=document.pdf" \
  -F "name=Документ.pdf"
```

Также принимается JSON с чистой base64-строкой. Передавайте filename с расширением .pdf; без него генерируется имя без расширения. Формат data:application/pdf;base64,... отдельно не поддерживается.

```
{
  "file": "<base64 PDF без префикса data:>",
  "filename": "document.pdf",
  "name": "Документ.pdf"
}
```

Ответ 201 содержит объект файла:

```
{
  "id": 123,
  "name": "Документ.pdf",
  "download_url": "<URL хранилища>",
  "is_image": false,
  "author": 42,
  "created": "<datetime>",
  "updated": "<datetime>"
}
```

Сохраните id для создания задачи. download_url зависит от хранилища; формат и срок действия здесь не фиксированы. Защищённое скачивание: GET /api/file-manager/files/123/download/ с авторизацией file-manager.

5. Создание задачи

POST /api/recognition/tasks/
Authorization: Bearer <access_token>
Content-Type: application/json

```
{"files": [123], "template_id": 7}
```

Поле	Тип	Правило
files	integer[]	Обязательно. ID предварительно загруженных файлов. Передавайте непустой массив своих файлов.
template_id	integer	Необязательно. ID готового шаблона; без него сервис подбирает или создаёт шаблон.

Успешный ответ — 201 с детальным объектом задачи, а не 202. Запрос не ждёт завершения обработки. Параметры language, pages, dpi, ocr_only, callback_url, удалённый URL файла в этом контракте не объявлены.

```
{
  "id": 456,
  "template": null,
  "created_at": "<datetime>",
  "status": "PENDING",
  "status_display": {"id": "PENDING", "name": "Ожидает"},
  "errors": null,
  "updated_at": "<datetime>",
  "name": "<название задачи>",
  "current_state": null,
  "completion_percentage": 0,
  "raw_data": null,
  "result_data": null,
  "files": [{"id": 123, "name": "Документ.pdf", "...": "..."}]
}
```

6. Статусы и получение результата

GET /api/recognition/tasks/456/
Authorization: Bearer <access_token>

Статус	Значение
PENDING	Ожидает запуска; возможен возврат в ожидание при ограничении OCR.
RUNNING	Фоновая обработка выполняется.
DONE	Пайплайн завершён. Проверяйте фактическое наличие результата.
ERROR	Обработка завершилась ошибкой. Проверяйте errors и current_state.
Поле	Смысл
raw_data	Распознанный текст, объединённый из страниц/файлов через два перевода строки.
result_data	JSON структурированных данных. Состав зависит от json_schema шаблона; универсальная фиксированная схема реквизитов не задана.

Поле	Смысл
template	Краткий объект: id, name, description, created_at, updated_at; либо null.
files	Массив объектов исходных файлов, как в ответе загрузки.
current_state	Человекочитаемый этап. Не используйте как стабильный машинный код.
completion_percentage	Целое число прогресса; не гарантирует готовность или монотонность.
errors	Текст проблем либо null; может присутствовать и при DONE.

Рекомендуемый клиентский алгоритм: сохранить ID → повторять GET с паузой (например, 3–5 секунд; это рекомендация, не лимит API) → на DONE проверить raw_data, result_data и errors → на ERROR показать диагностическое сообщение. Установите собственный предел ожидания: некоторые отрицательные сценарии могут оставлять RUNNING.

Отдельные координаты текста, confidence, список результатов по страницам и ID операции OCR-провайдера в этом ответе не предусмотрены. Подтверждённого webhook, внешнего cancel/retry и гарантии срока выполнения нет.

7. Шаблоны распознавания

POST /api/recognition/templates/
 Authorization: Bearer <access_token>
 Content-Type: application/json

```
{"files": [123], "description": "Счета поставщиков"}
```

files — обязательный массив ID файлов-примеров; description необязательно, допускает пустую строку. Шаблон создаётся с временным именем; JSON Schema строится асинхронно. Отдельного статуса готовности нет. Перед использованием проверяйте json_schema через GET detail: шаблон без схемы приводит к ошибке задачи.

```
{
  "id": 7,
  "name": "<название шаблона>",
  "description": "Счета поставщиков",
  "created_at": "<datetime>",
  "updated_at": "<datetime>",
  "json_schema": {"<схема конкретного документа>": "..."},
  "file_examples": []
}
```

8. Списки и пагинация

Списки файлов, задач и шаблонов используют постраничную выдачу по 20 записей: ?page=2. В списке задач нет raw_data, result_data и files — за результатом обращайтесь к detail. Задачи и шаблоны по умолчанию сортируются по убыванию даты создания.

```
{
  "count": 25,
  "next": "<URL следующей страницы>",
  "previous": null,
  "results": []
}
```

9. Ошибки

Разделяйте ошибку HTTP при создании запроса и ошибку фоновой обработки после успешного 201. Для обработанных ошибок DRF сервис использует следующую оболочку; details может отсутствовать:

```
{
  "error": "<сообщение>",
  "message": "<сообщение>",
  "code": "<код ошибки>",
  "details": "<дополнительные сведения>"
}
```

HTTP	Типичные причины
400	Обязательное поле не передано, неверный тип данных, ошибка base64.
401 / 403	Неверная или отсутствующая авторизация. Для recognition возможен 403 из-за порядка auth-классов; для file-manager обычно 401.
403	CSRF при сессии либо недостаточные права.
404	Файл/задача отсутствует или не видна текущему пользователю.
405 / 415	Неподдерживаемый метод / тип тела запроса.
413	Тело запроса превышает инфраструктурный лимит; JSON-ответ не гарантирован.
500	Внутренняя ошибка, в том числе при несуществующем ID файла.

После 201 ошибки OCR/структурирования отражаются в status, errors и current_state. errors — свободный текст, не перечисление стабильных кодов. Ограничение запросов OCR-провайдера обрабатывается в фоне с повторными попытками и не означает HTTP 429 при создании задачи.

10. Ограничения и особенности реализации

- Основной документированный сценарий этого руководства — PDF. В коде есть ветка OCR изображений, но полная матрица форматов не подтверждена. MIME определяется по расширению; PDF без правильного расширения не считается гарантированно валидным входом.
- В просмотренных сериализаторах нет явного предела размера PDF, количества страниц или числа файлов. Это не обещание обработки файлов любого размера. Реальные пределы OCR-провайдера и рабочий лимит сервиса отдельно не подтверждены.
- Поддержка PDF с паролем, повреждённых PDF и конкретные требования к качеству скана не подтверждены. Обработка читает файл целиком; для интеграции начинайте с небольших корректных PDF.
- При отсутствии файлов либо распознанного текста статус в некоторых ветках остаётся RUNNING. DONE не гарантирует непустой result_data и отсутствие errors. Проверяйте статус вместе с данными и собственным timeout.
- Повторный POST не имеет подтверждённого ключа идемпотентности и может создавать дубликаты. Не повторяйте запрос на создание вслепую после сетевого сбоя.
- Списки файлов и задач ограничены текущим пользователем. Шаблоны в исследованном коде не фильтруются по автору; проверки принадлежности переданных ID при создании не полностью реализованы. Используйте только свои файлы и согласованные шаблоны; эти особенности не являются разрешением доступа к чужим данным.
- Создание задачи API само по себе не является подтверждённым контрактом записи документа в 1С. Оно возвращает результаты распознавания; перенос в учётную систему — отдельный

сценарий.

11. Сквозной пример curl

Требуется curl и jq. BILLING_TOKEN и ACCESS_TOKEN заранее задайте безопасным способом; не сохраняйте реальные значения в примере. Оба токена должны представлять одного пользователя.

```
BASE="https://aether-lab.ru"

UPLOAD=$(curl --fail-with-body -sS \
  "$BASE/api/file-manager/files/" \
  -H "X-Billing-Token: $BILLING_TOKEN" \
  -F "file=@./document.pdf;type=application/pdf" \
  -F "filename=document.pdf")
FILE_ID=$(printf "%s" "$UPLOAD" | jq -er ".id")

TASK=$(curl --fail-with-body -sS \
  "$BASE/api/recognition/tasks/" \
  -H "Authorization: Bearer $ACCESS_TOKEN" \
  -H "Content-Type: application/json" \
  --data "$(jq -nc --argjson id "$FILE_ID" '{files:[$id]}')")
TASK_ID=$(printf "%s" "$TASK" | jq -er ".id")

# Повторяйте GET с паузой и собственным пределом ожидания.
curl --fail-with-body -sS \
  "$BASE/api/recognition/tasks/$TASK_ID/" \
  -H "Authorization: Bearer $ACCESS_TOKEN" | \
  jq '{status,current_state,errors,raw_data,result_data}'
```

12. Источники и интерактивная документация

Описание основано на коде, а не на выполненном запросе к production. В базе знаний подтверждено существование Консоли распознавания, но точный API-контракт в ней отсутствует. Внутренние инструменты агентного OCR и API OCR-провайдера не являются внешними REST-методами Aether Lab и здесь не описываются как клиентский контракт.

Интерактивные страницы: <https://aether-lab.ru/api/recognition/swagger/> и [/api/recognition/redoc/](https://aether-lab.ru/api/recognition/redoc/) — требуют авторизацию. [/api/file-manager/redoc/](https://aether-lab.ru/api/file-manager/redoc/) — для администратора.

[coder/urls.py](#); [coder/settings.py](#) — маршруты, JWT, пагинация.

[recognition_service/urls.py](#); [views.py](#); [serializers.py](#); [choices.py](#); [models.py](#) — HTTP-контракт и данные.

[recognition_service/tasks.py](#); [tools.py](#); [agent.py](#) — фоновая обработка, статусы, результаты.

[file_manager/urls.py](#); [views.py](#); [serializers.py](#) — загрузка и скачивание.

[billing/authentication.py](#); [coder/exception_handler.py](#) — billing token и ошибки.

[prod/nginx/django_app.conf](#) — базовый адрес развёртывания.